

**Otkrivanje nepravilnosti u financijskim
izvještajima primjenom Benfordovog zakona:
Analiza 442 poduzeća iz indeksa S&P 500**

Diplomski rad

Razdoblje analize: 2014. – 2024.

Broj analiziranih poduzeća: 442

Izvor podataka: SEC EDGAR Financial Statement Data Sets

Siječanj 2026.

Sažetak

Ovaj diplomski rad primjenjuje Benfordov zakon na analizu distribucije prvih znamenki financijskih podataka iz izvještaja 442 javno listana američka poduzeća u razdoblju od 11 godina (2014. – 2024.). Korištenjem podataka iz baze SEC EDGAR izračunate su hi-kvadrat statistike, srednje apsolutno odstupanje (MAD) te rezultati Kolmogorov-Smirnovljevog testa za svako promatranje poduzeće-godina.

Analiza otkriva da **97,5% poduzeća** pokazuje statistički značajno odstupanje od Benfordove očekivane distribucije ($p < 0,05$), s prosječnom hi-kvadrat vrijednošću od 59,83, što je gotovo četiri puta više od kritične vrijednosti 15,507. Identificiran je značajan **strukturni pomak nakon 2019. godine**, pri čemu su prosječne hi-kvadrat vrijednosti porasle za 24% u odnosu na razdoblje 2014. – 2018.

Studije slučaja poduzeća s visokim anomalijama (Medical Properties Trust, TANDEM Diabetes Care) i poduzeća s niskim anomalijama (Oracle) pružaju uvid u čimbenike koji utječu na sukladnost s Benfordovim zakonom. Važno je istaknuti da **nije utvrđen prediktivni odnos** ($r = 0,004$, $p = 0,827$) između Benfordovih anomalija u godini N i prinosa dionica u godini $N+1$, što ukazuje na to da nepravilnosti u financijskom izvještavanju ne predviđaju buduće investicijske prinose.

Ovi nalazi doprinose literaturi forenzičkog računovodstva i pružaju okvir za automatizirano pretraživanje financijskih izvještaja.

Ključne riječi: Benfordov zakon, forenzičko računovodstvo, otkrivanje prijevara, SEC izvještaji, hi-kvadrat test, analiza financijskih izvještaja

Sadržaj

1	Uvod	4
1.1	Pozadina i motivacija	4
1.2	Benfordov zakon: matematički temelji	4
1.3	Primjena u forenzičkom računovodstvu	5
1.4	Ciljevi istraživanja	6
2	Metodologija	7
2.1	Prikupljanje podataka	7
2.2	Statistički testovi	7
2.2.1	Hi-kvadrat test	7
2.2.2	Srednje apsolutno odstupanje (MAD)	7
2.2.3	Kolmogorov-Smirnovljev test	8
2.2.4	P-vrijednost	8
2.3	Klasifikacija rizika	8
3	Rezultati	9
3.1	Ukupne stope sukladnosti	9
3.2	Vremenski trendovi	10
3.3	Distribucija rizika	11
3.4	Najsumnjivija poduzeća	11
3.5	Poduzeća s najboljom sukladnošću	12
4	Studije slučaja	13
4.1	Poduzeće s visokim anomalijama: Medical Properties Trust	13
4.2	Korelacija s padom dionice: TANDEM Diabetes Care	14
4.3	Trendovi u studijama slučaja	15
4.4	Poduzeće s niskim anomalijama: Oracle Corporation	15
5	Analiza korelacije s cijenama dionica	16
5.1	Odgodena korelacija: predviđa li MAD u godini N prinose u godini $N+1$?	16
5.2	Ključni nalaz: nepostojanje prediktivnog odnosa	17
5.3	Benfordova analiza obujma trgovanja	18
6	Analiza toplinske karte	20
7	Rasprava	21
7.1	Interpretacija nalaza	21
7.2	Pomak nakon 2019. godine	21
7.3	Sektorski obrasci	21

7.4	Ograničenja	22
8	Zaključak	23
8.1	Sažetak nalaza	23
8.2	Implikacije	23
8.3	Buduća istraživanja	24
8.4	Završne napomene	24

1 Uvod

1.1 Pozadina i motivacija

Prijevare u financijskim izvještajima ostaju značajan problem za investitore, regulatore i revizore diljem svijeta. Tradicionalni revizijski postupci, premda neizostavni, ne mogu uvijek otkriti suptilne manipulacije u iskazanim iznosima. Benfordov zakon nudi snažan statistički alat za prepoznavanje anomalnih obrazaca koji zaslužuju dodatnu istragu.


Benfordov zakon, poznat i kao zakon prve znamenke, opisuje frekvencijsku distribuciju vodećih znamenki u brojnim prirodno nastalim skupovima podataka ([Benford, 1938](#)). Suprotno intuiciji, znamenke se ne pojavljuju s jednakom vjerojatnošću; znamenka 1 pojavljuje se kao prva znamenka u približno 30,1% slučajeva, dok se znamenka 9 pojavljuje u samo 4,6% slučajeva.

1.2 Benfordov zakon: matematički temelji

Vjerojatnost da se znamenka d pojavi kao prva značajna znamenka dana je izrazom:

$$P(d) = \log_{10} \left(1 + \frac{1}{d} \right), \quad d \in \{1, 2, \dots, 9\} \quad (1)$$

Ova formula daje očekivanu distribuciju prikazanu na slici [1](#).



Slika 1: Stupčasti dijagram očekivane distribucije prvih znamenki prema Benfordovom zakonu za znamenke od 1 do 9. Svaki stupac prikazuje teorijsku vjerojatnost pojavljivanja pojedine znamenke kao prve značajne znamenke u prirodno nastalim podacima. Znamenka 1 ima najveću očekivanu frekvenciju od 30,1%, a svaka sljedeća znamenka ima progresivno manju vjerojatnost, sve do znamenke 9 koja se očekuje u samo 4,6% slučajeva. Iznad svakog stupca navedena je točna postotna vrijednost. U gornjem desnom kutu prikazana je formula $P(d) = \log_{10}(1 + \frac{1}{d})$ koja definira ovu distribuciju.

Zakon je prvi otkrio astronom Simon Newcomb 1881. godine ([Newcomb, 1881](#)), a zatim ga je neovisno formulisao fizičar Frank Benford ([Benford, 1938](#)). Kasnije je matematički dokazan pod uvjetima invarijantnosti na skalu i bazu ([Hill, 1995](#)).

1.3 Primjena u forenzičkom računovodstvu

Primjenu Benfordovog zakona na računovodstvene podatke pokrenuli su [Carslaw \(1988\)](#) i [Thomas \(1989\)](#), koji su pronašli dokaze o manipulaciji zaradama u iskazanim iznosima dobiti. [Nigrini \(1996\)](#); [Nigrini and Mittermaier \(1997\)](#) razvio je praktične metodologije za revizore, uspostavljajući pragove za prepoznavanje sumnjivih odstupanja.

Ključna područja primjene uključuju:

- Otkrivanje prijevара u financijskim izvještajima
- Identificiranje poreznih prijevара
- Provjera izbornih rezultata
- Provjera integriteta znanstvenih podataka

1.4 Ciljevi istraživanja

Ovo istraživanje ima sljedeće ciljeve:

1. Analizirati sukladnost s Benfordovim zakonom za 442 velika američka javno listana poduzeća u razdoblju od 11 godina
2. Identificirati vremenske trendove i strukturne promjene u obrascima financijskog izvještavanja
3. Ispitati odnos između Benfordovih anomalija i performansi na tržištu dionica
4. Izraditi studije slučaja poduzeća s visokim i niskim anomalijama

2 Metodologija

2.1 Prikupljanje podataka

Financijski podaci prikupljeni su iz baze SEC EDGAR Financial Statement Data Sets ([U.S. Securities and Exchange Commission, 2024](#)), koja pruža standardizirane tromjesečne izvještaje za sva javno listana poduzeća. Skup podataka obuhvaća:

- **Vremensko razdoblje:** 1. tromjesečje 2014. do 4. tromjesečje 2024. (44 tromjesečja)
- **Poduzeća:** 442 jedinstvena SEC podnositelja
- **Opservacije:** 4862 zapisa poduzeće-godina

Za svako promatranje poduzeće-godina izdvojene su sve numeričke vrijednosti iz financijskih izvještaja, uz isključivanje nultih vrijednosti (koje narušavaju pretpostavke Benfordovog zakona) i uzimanje apsolutnih vrijednosti negativnih iznosa.

2.2 Statistički testovi

Primijenjena su četiri komplementarna statistička testa za procjenu sukladnosti s Benfordovim zakonom:

2.2.1 Hi-kvadrat test

Hi-kvadrat test dobrote prilagodbe uspoređuje opažene frekvencije s Benfordovom očekivanom distribucijom:

$$\chi^2 = \sum_{d=1}^9 \frac{(O_d - E_d)^2}{E_d} \quad (2)$$

gdje je O_d opaženi broj pojavljivanja, a $E_d = n \cdot P(d)$ očekivani broj pojavljivanja za znamenku d .

S 8 stupnjeva slobode, kritična vrijednost pri $\alpha = 0,05$ iznosi **15,507**.

2.2.2 Srednje apsolutno odstupanje (MAD)

MAD pruža intuitivniju mjeru odstupanja:

$$\text{MAD} = \frac{1}{9} \sum_{d=1}^9 |O_d\% - E_d\%| \quad (3)$$

Prema [Nigrini \(2012\)](#), koriste se sljedeći pragovi za interpretaciju:

Tablica 1: Pragovi za interpretaciju MAD vrijednosti kod testova prvih znamenki

Raspon MAD	Interpretacija	Razina rizika
$< 0,006$	Visoka sukladnost	Niska
$0,006 - 0,012$	Prihvatljiva sukladnost	Niska
$0,012 - 0,015$	Granično prihvatljivo	Srednja
$> 0,015$	Nesukladnost	Visoka

Napomena: U našoj implementaciji MAD vrijednosti iskazane su kao postoci (pomnožene sa 100), stoga pragovi postaju 1,5; 2,5 itd.

2.2.3 Kolmogorov-Smirnovljev test

KS test mjeri maksimalnu udaljenost između empirijske i teorijske kumulativne funkcije distribucije ([Kolmogorov, 1933](#)):

$$D = \max_d |F_n(d) - F(d)| \quad (4)$$

2.2.4 P-vrijednost

P-vrijednost iz hi-kvadrat testa označava vjerojatnost da se takvo odstupanje pojavi slučajno. Vrijednosti ispod 0,05 ukazuju na statistički značajno odstupanje od Benfordovog zakona.

2.3 Klasifikacija rizika

Poduzeća su klasificirana prema razinama rizika na temelju prosječnih MAD vrijednosti:

Tablica 2: Kriteriji klasifikacije rizika

Razina rizika	Raspon MAD	Oznaka bojom
Nizak rizik	$MAD < 1,5$	
Srednji rizik	$1,5 \leq MAD < 2,5$	
Visok rizik	$2,5 \leq MAD < 4,0$	
Kritičan rizik	$MAD \geq 4,0$	


3 Rezultati

3.1 Ukupne stope sukladnosti

Analiza otkriva rasprostranjeno odstupanje od Benfordovog zakona među javno listanim poduzećima:

- **97,5%** poduzeća pokazuje statistički značajno odstupanje ($p < 0,05$) u najmanje jednoj godini
- Prosječna hi-kvadrat vrijednost: **59,83** (nasuprot kritičnoj vrijednosti od 15,507)
- Prosječni MAD: **1,28** (što ukazuje na graničnu sukladnost)


Slika 2 prikazuje distribuciju MAD vrijednosti za sve opservacije poduzeće-godina.



Slika 2: Histogram distribucije MAD (srednje apsolutno odstupanje) vrijednosti za ukupno 4862 opservacije poduzeće-godina u razdoblju 2014. – 2024. Svaki stupac predstavlja broj opservacija unutar određenog raspona MAD vrijednosti, pri čemu su stupci obojeni prema razini rizika: zeleno za nizak rizik ($\text{MAD} < 1,5$), žuto za srednji rizik ($1,5 \leq \text{MAD} < 2,5$), narančasto za visok rizik ($2,5 \leq \text{MAD} < 4,0$) i crveno za kritičan rizik ($\text{MAD} \geq 4,0$). Zelena isprekidana okomita linija označava prag dobre sukladnosti ($\text{MAD} = 1,5$), a narančasta isprekidana linija označava prag zabrinjavajućeg odstupanja ($\text{MAD} = 2,5$). U gornjem desnom kutu prikazane su deskriptivne statistike: ukupan broj opservacija ($n = 4862$), aritmetička sredina (1,28) i medijan (1,27). Distribucija pokazuje da većina poduzeća ima MAD vrijednosti između 0,5 i 2,0, s dugim repom koji se proteže prema višim vrijednostima.

3.2 Vremenski trendovi

Ključni nalaz jest **strukturni pomak nakon 2019. godine** u sukladnosti s Benfordovim zakonom, prikazan na slici 3.



Slika 3: Vremenski trendovi rezultata hi-kvadrat testa za 442 poduzeća po godinama od 2014. do 2024. Plava linija s kružnim markerima prikazuje prosječnu hi-kvadrat vrijednost svih poduzeća za svaku godinu, a zelena isprekidana linija prikazuje medijan. Svijetloplavo zasjenjeno područje oko prosjeka predstavlja raspon jedne standardne devijacije. Crvena vodoravna isprekidana linija označava kritičnu vrijednost hi-kvadrat testa od 15,507 (8 stupnjeva slobode, $\alpha = 0,05$), iznad koje odstupanje od Benfordovog zakona postaje statistički značajno. Sivi stupci na pozadini (desna os y) prikazuju postotak poduzeća čija je p -vrijednost manja od 0,05 u svakoj godini. Vidljiv je strukturni pomak nakon 2019. godine: prosječna hi-kvadrat vrijednost porasla je s otprilike 45 u razdoblju 2014. – 2018. na 55 – 60 u razdoblju 2019. – 2024.

Ključna zapažanja:

- **2014. – 2018.:** Prosječna hi-kvadrat vrijednost ≈ 45 (relativno stabilna)
- **2019.:** Nagli porast na 55,78 (skok od 24%)
- **2020. – 2024.:** Održana povišena razina od 57 do 60


Mogući uzroci uključuju:

1. Povećanu složenost standarda financijskog izvještavanja
2. Učinke pandemije COVID-19 na računovodstvene procjene
3. Veću primjenu mjerenja fer vrijednosti

4. Promjene u metodologiji prikupljanja podataka SEC-a

3.3 Distribucija rizika

Slika 4 prikazuje ukupnu distribuciju rizika za 442 poduzeća na temelju prosječnih MAD vrijednosti.



Slika 4: Tortni dijagram distribucije rizika za 442 poduzeća, klasificirana prema prosječnoj MAD vrijednosti kroz čitavo promatrano razdoblje 2014. – 2024. Svaki isječak predstavlja jednu kategoriju rizika: zelena boja označava nizak rizik ($MAD < 1,5$), žuta srednji rizik ($1,5 \leq MAD < 2,5$), narančasta visok rizik ($2,5 \leq MAD < 4,0$) i crvena kritičan rizik ($MAD \geq 4,0$). Unutar svakog isječka naveden je postotak i apsolutni broj poduzeća. Najveći udio od 69,0% (304 poduzeća) spada u kategoriju niskog rizika, dok 30,3% (134 poduzeća) pripada srednjem riziku. Kategorije visokog i kritičnog rizika čine zanemariv udio ukupnog uzorka.

3.4 Najsumnjivija poduzeća

Tablica 3 prikazuje 10 poduzeća s najvišim prosječnim rezultatima anomalija.

Tablica 3: 10 najsumnjivijih poduzeća (najviša prosječna hi-kvadrat vrijednost)

Rang	Poduzeće	Pros. χ^2	Maks. χ^2	Najgori prinos
1	Medical Properties Trust	152,87	311,27	−52,0%
2	Healthcare Realty Trust	132,91	285,59	−18,4%
3	Summit Hotel Properties	118,26	308,96	−32,6%
4	Cogent Communications	117,67	178,73	−16,6%
5	Crown Castle Inc.	116,64	228,36	−32,2%
6	MASIMO Corp	112,04	282,63	−48,1%
7	TrustCo Bank Corp	106,43	154,93	−20,4%
8	HNI Corp	104,91	181,77	−31,0%
9	Kimco Realty Corp	104,63	228,27	−24,3%
10	Western Alliance Bancorporation	103,20	182,30	− 44,6%

3.5 Poduzeća s najboljom sukladnošću

Tablica 4 prikazuje poduzeća s najnižim rezultatima anomalija, odnosno ona čiji financijski izvještaji najbolje slijede Benfordov zakon.

Tablica 4: 10 poduzeća s najboljom sukladnošću (najniža prosječna hi-kvadrat vrijednost)

Rang	Poduzeće	Pros. χ^2	Pros. MAD	Pros. p-vrij.
1	Philip Morris International	16,43	0,84	0,175
2	Oracle Corporation	16,55	0,88	0,201
3	Take-Two Interactive	17,14	0,93	0,114
4	Jacobs Solutions Inc.	17,25	0,85	0,160
5	Ciena Corp	20,45	1,04	0,047
6	Emerson Electric Co	21,24	0,96	0,046
7	Enphase Energy, Inc.	21,35	1,15	0,112
8	Mondelez International	21,89	0,83	0,156
9	American Woodmark Corp	23,05	1,30	0,024
10	Dover Corp	23,44	1,08	0,030


4 Studije slučaja

4.1 Poduzeće s visokim anomalijama: Medical Properties Trust

Medical Properties Trust (NYSE: MPW) pokazuje **najvišu prosječnu hi-kvadrat vrijednost** u skupu podataka (**152,87**) te najvišu jednogodišnju hi-kvadrat vrijednost od **311,27** (u 2023. godini). U kombinaciji s najgorim godišnjim prinosom od $-52,0\%$, ovo poduzeće predstavlja uvjerljivu studiju slučaja:

- Trajno povišena hi-kvadrat vrijednost kroz sve godine, s naglim porastom od 2019. nadalje
- Prezastupljenost znamenke 5 ($13,3\%$ nasuprot očekivanim $7,9\%$) i znamenke 8 ($8,9\%$ nasuprot očekivanim $5,1\%$)
- Podzastupljenost znamenki 3 i 4, što ukazuje na netipične obrasce financijskih podataka
- Pad dionice od $52,0\%$ u najgoroj godini, što korelira s razdobljem najviših anomalija

Slika 5 uspoređuje distribuciju znamenki poduzeća Medical Properties Trust s Benfordovim očekivanjima i poduzećem Oracle (koje pokazuje dobru sukladnost).



Slika 5: Stupčasti dijagram koji uspoređuje distribuciju prvih znamenki (1–9) za tri skupa podataka, prikazanih kao tri stupca za svaku znamenku. Plavi stupci prikazuju Benfordovu teorijski očekivanu distribuciju, zeleni stupci prikazuju opaženu distribuciju za Oracle Corporation (poduzeće s najboljom sukladnošću, prosječni $\chi^2 = 16,55$), a crveni stupci prikazuju opaženu distribuciju za Medical Properties Trust (najsumnjivije poduzeće, prosječni $\chi^2 = 152,87$). Os y prikazuje frekvenciju pojavljivanja u postocima. Oracle gotovo savršeno prati Benfordovu krivulju, s frekvencijom znamenke 1 od 29,8% (očekivano 30,1%). Medical Properties Trust pokazuje značajna odstupanja: znamenka 5 pojavljuje se u 13,3% slučajeva (očekivano 7,9%), a znamenka 8 u 8,9% (očekivano 5,1%), dok su znamenke 3 i 4 podzastupljene.

4.2 Korelacija s padom dionice: TANDEM Diabetes Care


TANDEM Diabetes Care (NASDAQ: TNDM) predstavlja najdramatičniji slučaj korelacije Benfordovih anomalija s performansama dionice:

- Prosječna hi-kvadrat vrijednost: 62,0 (četiri puta iznad kritičnog praga)
- **Najgori godišnji prinos:** $-88,8\%$ (2017. godina, jedan od najvećih padova u skupu podataka)
- Ekstremna volatilnost: nakon pada od $-88,8\%$ u 2017., dionica je zabilježila rast od $+1394,9\%$ u 2018., a zatim ponovni pad od $-70,1\%$ u 2022.
- Obrazac sugerira da su problemi u financijskom izvještavanju prethodili tržišnom prepoznavanju

Ovaj slučaj pokazuje kako Benfordova analiza može poslužiti kao sustav ranog upozorenja za investitore.

4.3 Trendovi u studijama slučaja

Slika 6 prikazuje trendove MAD vrijednosti za četiri poduzeća iz studija slučaja tijekom promatranog razdoblja.



Slika 6: Linijski dijagram koji prikazuje trendove MAD vrijednosti kroz godine 2014. – 2024. za četiri odabrana poduzeća iz studija slučaja. Svaka linija s kružnim markerima predstavlja jedno poduzeće: Medical Properties Trust (najviši prosječni $\chi^2 = 152,87$), TANDEM Diabetes Care (najgori prinos dionice od $-88,8\%$), Semtech Corp ($\chi^2 = 88,6$, prinos -68%) i Oracle Corporation (referentno poduzeće s dobrom sukladnošću). Zelena vodoravna isprekidana linija označava prag dobre sukladnosti ($MAD = 1,5$), a crvena isprekidana linija označava prag zabrinjavajućeg odstupanja ($MAD = 2,5$). Medical Properties Trust dosljedno prelazi oba praga, dok Oracle ostaje ispod praga od 1,5 gotovo u svim godinama. TANDEM i Semtech pokazuju volatilne obrasce s naglim skokovima i padovima između godina.

4.4 Poduzeće s niskim anomalijama: Oracle Corporation

Oracle Corporation dosljedno održava izvrsnu sukladnost s Benfordovim zakonom:

- Prosječna hi-kvadrat vrijednost: 16,55 (blizu kritične vrijednosti od 15,507)
- Prosječna p-vrijednost: 0,201 (nije statistički značajno)
- Frekvencija znamenke 1: 29,8% (vrlo blizu očekivanih 30,1%)

Čimbenici koji tome mogu pridonijeti uključuju:


1. Velike, diversificirane tokove prihoda
2. Zrele, stabilne procese financijskog izvještavanja
3. Veliki obujam podataka koji smanjuje učinke uzorkovanja

5 Analiza korelacije s cijenama dionica

5.1 Odgođena korelacija: predviđa li MAD u godini N prinose u godini $N+1$?

Ključno pitanje jest mogu li Benfordove anomalije u financijskim izvještajima jedne godine *predvidjeti* prinose dionica u sljedećoj godini. Ako tržište sporo otkriva financijske nepravilnosti, mogla bi se pojaviti odgođena povezanost.

Izračunata je Pearsonova korelacija između MAD vrijednosti svakog poduzeća u godini N i godišnjeg prinosa dionice u godini $N+1$, za sve uzastopne parove godina od 2014./2015. do 2023./2024. (ukupno 3490 opservacija za 438 poduzeća). Slika 7 prikazuje skupni dijagram raspršenja.



Slika 7: Dijagram raspršenja koji prikazuje odgođenu korelaciju između MAD vrijednosti u godini N (os x) i godišnjeg prinosa dionice u godini $N+1$ (os y) za ukupno 3490 opservacija poduzeće-godina u razdoblju 2014.–2024. Svaka točka predstavlja jedno poduzeće u jednoj godini, a boja točke odgovara njezinoj MAD vrijednosti prema skali boja s desne strane (zelena za nizak MAD, crvena za visok MAD). Crvena isprekidana linija prikazuje linearnu regresiju koja je gotovo potpuno vodoravna, potvrđujući zanemariv odnos ($r = 0,004$, $p = 0,827$). Zelena okomita isprekidana linija označava prag dobre sukladnosti ($MAD = 1,5$), a crvena okomita isprekidana linija prag zabrinjavajućeg odstupanja ($MAD = 2,5$). Crna vodoravna linija označava nulti prinos. Raspršenost točaka bez vidljivog obrasca potvrđuje da Benfordove anomalije u financijskim izvještajima ne predviđaju buduće prinose dionica.

5.2 Ključni nalaz: nepostojanje prediktivnog odnosa


Analiza otkriva:

- **Skupna korelacija:** $r = 0,004$ ($p = 0,827$), što ukazuje na nepostojanje prediktivnog odnosa.
- **Analiza po parovima godina:** Nijedan pojedinačni par godina nije dosegao statističku značajnost pri $p < 0,05$. Par 2021./2022. pokazao je najjači signal

($r = -0,094$, $p = 0,08$), što moguće odražava tržišne turbulencije tijekom korekcije 2022. godine.

- **Nedosljednost smjera:** Korelacije su se izmjenjivale između pozitivnih i negativnih vrijednosti kroz parove godina, što dodatno potvrđuje odsutnost sustavnog odgođenog učinka.

Slika 8 detaljnije prikazuje korelacije za svaki pojedinačni par uzastopnih godina.



Slika 8: Analiza odgođene korelacije po parovima godina. Panel (a) prikazuje Pearsonove r koeficijente korelacije za svaki par uzastopnih godina (npr. MAD iz 2014. u odnosu na prinos u 2015.), pri čemu sivi stupci označavaju statistički neznačajne rezultate ($p \geq 0,05$), a crveni stupci bi označavali značajne ($p < 0,05$). Nijedan par godina nije dosegao statističku značajnost. Korelacije se izmjenjuju između pozitivnih i negativnih vrijednosti, pri čemu je najjači negativni signal zabilježen za par 2021./2022. ($r = -0,094$). Panel (b) prikazuje skupni dijagram raspršenja svih 3490 opservacija, gdje svaka točka predstavlja jedno poduzeće-godinu s MAD vrijednošću na osi x i prinosom dionice sljedeće godine na osi y . Crvena linija regresije gotovo je potpuno vodoravna, potvrđujući zanemariv odnos ($r = 0,004$, $p = 0,827$).


Interpretacija: Ovaj rezultat sukladan je s hipotezom efikasnog tržišta: kad bi Benfordova odstupanja sadržavala iskoristivu informaciju, racionalni investitori bi je brzo ugradili u cijene, eliminirajući odgođeni signal. Mogući razlozi za odsutnost korelacije su:

1. Odstupanja često odražavaju legitimnu računovodstvenu složenost, a ne prijevaru
2. Tržišta su već mogla ugraditi kvalitetu računovodstva u cijene
3. Prinosi dionica primarno su uvjetovani temeljnim poslovnim performansama

5.3 Benfordova analiza obujma trgovanja

Alternativna perspektiva ispituje pokazuju li poduzeća s anomalnim financijskim izvještajima ujedno i neobične obrasce obujma trgovanja. Primjena Benfordovog zakona na

dnevne obujme trgovanja pruža drugu, neovisnu mjeru “numeričke pravilnosti”. Izračunat je Benfordov MAD dnevnih obujmova trgovanja za svako poduzeće-godinu te koreliran s odgovarajućim MAD-om financijskih izvještaja. Slika 9 prikazuje rezultate.



Slika 9: Dvodijelna vizualizacija korelacije između Benfordovog MAD-a financijskih izvještaja i Benfordovog MAD-a dnevnih obujmova trgovanja. Panel (a) prikazuje stupčasti dijagram Pearsonovih r koeficijenata korelacije za svaku godinu od 2014. do 2024., pri čemu crveni stupci označavaju statistički značajne rezultate ($p < 0,05$), a sivi neznačajne ($p \geq 0,05$). Negativna korelacija opažena je u 9 od 11 godina, s vrijednostima u rasponu od $r = -0,09$ do $r = -0,29$. Panel (b) prikazuje skupni dijagram raspršenja svih 3832 opservacije, gdje svaka točka predstavlja jedno poduzeće-godinu: os x prikazuje MAD financijskih izvještaja, a os y MAD obujma trgovanja. Crvena linija regresije ima negativan nagib, potvrđujući skupnu korelaciju od $r = -0,160$ ($p < 0,001$). Ovaj protuintuitivni rezultat sugerira da poduzeća s većim nepravilnostima u financijskim izvještajima imaju pravilnije obrasce obujma trgovanja.


Ključni nalazi:

- **Skupna korelacija:** $r = -0,160$ ($p < 0,001$), statistički značajan negativan odnos.
- **Dosljednost:** Negativna korelacija opažena je u 9 od 11 godina, s vrijednostima u rasponu od $r = -0,09$ do $r = -0,29$.
- **Interpretacija:** Poduzeća s većim nepravilnostima u financijskim izvještajima (visok MAD) imaju tendenciju *pravilnijih* obrazaca obujma trgovanja (nizak MAD obujma). Ovaj protuintuitivni rezultat može odražavati činjenicu da poduzeća sa složenim financijskim izvještajima obično spadaju među veće, likvidnije dionice čiji obujmi trgovanja prirodno slijede glatkije distribucije sukladnije Benfordovom zakonu.

Ovaj nalaz ukazuje na to da anomalije u financijskim izvještajima i obrasci obujma trgovanja obuhvaćaju bitno različite aspekte numeričkog profila poduzeća te da sukladnost s Benfordovim zakonom u jednoj domeni ne implicira sukladnost u drugoj.

6 Analiza toplinske karte

Slika 10 pruža sveobuhvatan pregled 30 najsumnjivijih poduzeća kroz sve godine.



Slika 10: Toplinska karta (heatmap) MAD vrijednosti za 30 najsumnjivijih poduzeća u razdoblju 2014. – 2024., rangiranih od vrha prema dnu po prosječnoj MAD vrijednosti. Svaka ćelija matrice prikazuje MAD vrijednost jednog poduzeća u jednoj godini, obojenu prema skali boja prikazanoj s desne strane: tamno zelena označava nisku MAD vrijednost (dobra sukladnost), žuta srednju, a tamno crvena visoku MAD vrijednost (sumnjivo odstupanje, $MAD > 4,0$). Okomita os prikazuje nazive poduzeća, a vodoravna os godine od 2014. do 2024. Okomiti pojasevi intenzivnije boje (npr. oko 2018. i 2020.) ukazuju na učinke specifične za pojedine godine koji istodobno utječu na više poduzeća. Među 30 najsumnjivijih nerazmjerno su zastupljeni REIT-ovi (investicijski fondovi u nekretnine) i poduzeća iz sektora ugostiteljstva.

Uočeni obrasci:

- Okomiti pojasevi ukazuju na učinke specifične za pojedine godine (npr. 2018., 2020.)
- Neka poduzeća pokazuju dosljedno povišene vrijednosti kroz sve godine
- REIT-ovi i poduzeća iz sektora ugostiteljstva nerazmjerno su zastupljeni

7 Rasprava

7.1 Interpretacija nalaza

Visoka stopa Benfordovog odstupanja (97,5%) među poduzećima iz indeksa S&P 500 upadljiva je, ali zahtijeva opreznu interpretaciju:

1. **Statistička značajnost $\neq$ praktična značajnost:** S velikim uzorcima (tisućama stavki po poduzeću), čak i manja odstupanja postaju statistički značajna.
2. **Legitimni uzroci odstupanja:** Politike zaokruživanja, računovodstvene prakse specifične za sektor i učinci agregiranja podataka mogu uzrokovati neprijevarna odstupanja.
3. **Benfordov zakon kao alat za pretraživanje:** Visoko odstupanje označava poduzeća za daljnju istragu, a ne za automatsko utvrđivanje prijevare.

7.2 Pomak nakon 2019. godine

Porast hi-kvadrat vrijednosti od 24% nakon 2019. godine zaslužuje pozornost. Mogući uzroci uključuju:

- Pandemija COVID-19 koja je unijela neuobičajene računovodstvene procjene
- Povećana primjena mjerenja fer vrijednosti prema ASC 820
- Promjene u metodologiji prikupljanja podataka SEC EDGAR-a
- Veća složenost priznavanja prihoda (primjena ASC 606)

7.3 Sektorski obrasci

Investicijski fondovi u nekretnine (REIT-ovi) i poduzeća iz sektora ugostiteljstva pokazuju povišene stope anomalija. To može odražavati:

- Intenzivnu primjenu računovodstva fer vrijednosti za vrednovanje nekretnina
- Sezonske obrasce prihoda koji stvaraju grupiranje znamenki
- Računovodstvene konvencije specifične za sektor

7.4 Ograničenja

1. **Granularnost podataka:** SEC EDGAR pruža agregirane podatke; podaci o pojedinačnim transakcijama mogli bi pokazati bolju sukladnost.
2. **Odabir uzorka:** Usmjerenost na poduzeća iz indeksa S&P 500 možda se ne može generalizirati na manja poduzeća.
3. **Nepostojanje referentne istine:** Bez potvrđenih slučajeva prijevare ne možemo validirati prediktivnu točnost.
4. **Analiza druge znamenke:** Ovo istraživanje usmjereno je primarno na testove prvih znamenki; analiza drugih znamenki mogla bi otkriti dodatne obrasce.

8 Zaključak

8.1 Sažetak nalaza

Ovaj diplomski rad analizirao je sukladnost s Benfordovim zakonom za 442 poduzeća iz indeksa S&P 500 u razdoblju od 11 godina (2014. – 2024.), otkrivši:

1. **Rasprostranjeno odstupanje:** 97,5% poduzeća pokazuje statistički značajno odstupanje od Benfordove očekivane distribucije.
2. **Vremenski pomak:** Porast prosječnih hi-kvadrat vrijednosti od 24% nakon 2019. godine, potencijalno povezan s pandemijom COVID-19 i promjenama računovodstvenih standarda.
3. **Nepostojanje prediktivnog odnosa:** Odgođena korelacija između Benfordovih anomalija u godini N i prinosa dionica u godini $N+1$ iznosi $r = 0,004$ ($p = 0,827$), što ukazuje na potpunu odsutnost prediktivne moći.
4. **Divergencija obujma i financijskih izvještaja:** Značajna negativna korelacija ($r = -0,160$, $p < 0,001$) između MAD-a financijskih izvještaja i MAD-a obujma trgovanja ukazuje na to da oni obuhvaćaju bitno različita numerička svojstva.
5. **Sektorski učinci:** REIT-ovi i poduzeća iz sektora ugostiteljstva pokazuju sustavno više stope anomalija.
6. **Sustavni obrasci:** Dvogodišnji oscilacijski obrasci kod 11 poduzeća ukazuju na artefakte strukture podataka, a ne na prijevaru.

8.2 Implikacije

Za revizore i regulatore:

- Benfordova analiza koristan je alat za pretraživanje, ali zahtijeva kontekstualnu interpretaciju
- Pragovi specifični za sektor mogli bi poboljšati točnost
- Automatizirano pretraživanje može optimizirati ograničene revizijske resurse

Za investitore:

- Visoki rezultati Benfordovih anomalija sami po sebi ne predviđaju loše performanse dionice
- U kombinaciji s drugim signalima, otkrivanje anomalija može ukazati na probleme s kvalitetom računovodstva

8.3 Buduća istraživanja

Preporučena proširenja uključuju:

1. Analizu drugih znamenki za otkrivanje manipulacije zaokruživanjem
2. Integraciju strojnog učenja za višefaktorsko otkrivanje anomalija
3. Longitudinalno praćenje označenih poduzeća radi ishoda prijevara
4. Međunarodnu usporedbu različitih računovodstvenih standarda

8.4 Završne napomene

Benfordov zakon pruža snažan, objektivan alat za analizu financijskih izvještaja. Premda sam po sebi nije detektor prijevara, nudi vrijedne uvide u kvalitetu podataka i računovodstvene prakse. Ovaj diplomski rad demonstrira korisnost i ograničenja Benfordove analize u suvremenoj financijskoj forenzici.

Literatura

- Benford, F. (1938). The law of anomalous numbers. *Proceedings of the American Philosophical Society*, 78(4):551–572.
- Carslaw, C. A. P. N. (1988). Anomalies in income numbers: Evidence of goal oriented behavior. *The Accounting Review*, 63(2):321–327.
- Hill, T. P. (1995). A statistical derivation of the significant-digit law. *Statistical Science*, 10(4):354–363.
- Kolmogorov, A. (1933). Sulla determinazione empirica di una legge di distribuzione. *Giornale dell'Istituto Italiano degli Attuari*, 4:83–91.
- Newcomb, S. (1881). Note on the frequency of use of the different digits in natural numbers. *American Journal of Mathematics*, 4(1):39–40.
- Nigrini, M. J. (1996). A taxpayer compliance application of benford's law. *Journal of the American Taxation Association*, 18(1):72–91.
- Nigrini, M. J. (2012). *Benford's Law: Applications for Forensic Accounting, Auditing, and Fraud Detection*. John Wiley & Sons, Hoboken, NJ.
- Nigrini, M. J. and Mittermaier, L. J. (1997). The use of benford's law as an aid in analytical procedures. *Auditing: A Journal of Practice & Theory*, 16(2):52–67.
- Thomas, J. K. (1989). Unusual patterns in reported earnings. *The Accounting Review*, 64(4):773–787.
- U.S. Securities and Exchange Commission (2024). Financial statement data sets. <https://www.sec.gov/dera/data/financial-statement-data-sets>. Accessed: 2024.